

Khoa Công Nghệ Thông Tin



**Industrial
University of
Ho Chi Minh City**

**BÁO CÁO ĐỒ ÁN MÔN HỌC
HỌC SÂU (DEEP LEARNING)**

Đồ án 06: Phát Hiện Ảnh Bất Thường

Giảng viên hướng dẫn: Lê Vũ Hạo

Lớp: DHKHM19ATT

Thành viên nhóm:

Mã SV	Họ tên
23676671	Lê Hoàng Anh
23681811	Huỳnh Thị Ngọc Tiên

TP.Hồ Chí Minh năm 2026

Mục lục

Catalog

Mục lục	2
Danh Sách Bảng	4
Danh Sách Hình	4
Chương 1 Giới thiệu	6
1.1 Bối cảnh và động cơ	6
1.1.1 Bối ảnh bài toán	6
1.1.2 Động cơ bài toán	6
1.2 Mục tiêu đề án	7
1.2.1 (CLO1) Phân tích bài toán và thiết kế mô hình Deep Learning: ..	7
1.2.2 (CLO2) – Triển khai và thực nghiệm	7
1.2.3 (CLO3) – Đánh giá và vận dụng	7
1.3 Phạm vi và cấu trúc báo cáo	8
Chương 2 Cơ sở lý thuyết và nghiên cứu liên quan	9
2.1 Kiến thức nền tảng	9
2.1.1 Tổng quan về Deep Learning	9
2.1.2 Convolutional Neural Network (CNN)	9
2.1.3 Autoencoder	9
2.1.4 Denoising Autoencoder	9
2.1.5 Recurrent Neural Network (RNN) và LSTM	10
2.1.6 Transformer	10
2.1.7 Chỉ số đánh giá	10
2.2 Các nghiên cứu hoặc mô hình liên quan	10
Chương 3 Bài toán và dữ liệu	11
3.1 Mô tả bài toán	11
3.1.1 Đầu vào (Input)	11
3.1.2 Đầu ra (Output)	11
3.1.3 Giả định và ràng buộc	11
3.2 Dataset	12
3.2.1 Nguồn dữ liệu	12
3.2.2 Tiền xử lý dữ liệu	13
3.2.2.1 Chuẩn hóa dữ liệu	13
3.2.2.2 Tăng cường dữ liệu (Data Augmentation)	13

3.2.2.3 Xử lý mất cân bằng dữ liệu	13
Chương 4 Phương pháp đề xuất	14
4.1 Mô hình 1 (Baseline)	14
4.1.1 Ý tưởng mô hình	14
4.2.2 Kiến trúc mô hình	14
4.1.3 Số tham số	14
4.1.4 Sơ đồ mô hình	15
4.2 Mô hình 2 (Nâng cao)	15
4.2.1 Kiến trúc mô hình nâng cao	15
4.2.2 Phương pháp đánh giá bất thường	16
4.2.3 Kỳ vọng cải thiện	16
4.2.4 Sơ đồ mô hình 2	17
4.3 Hàm mất mát và thuật toán tối ưu	17
4.3.1 Đối với dữ liệu Hazelnut	17
4.3.2 Đối với dữ liệu Bottle	19
4.3.3 Đối với dữ liệu CIFAR-10 (one-class)	21
Chương 5 Thực nghiệm và đánh giá	23
5.1 Thiết lập thí nghiệm	23
5.1.1 Môi trường thực nghiệm	23
5.1.2 Phân cứng sử dụng	24
5.1.3 Siêu tham số sử dụng	24
5.2 Kết quả định lượng	24
5.2.1 Bảng so sánh mô hình (Hazelnut – Adam + Weight Decay)	25
5.2.2 Bảng so sánh mô hình (Bottle – Adam + Weight Decay)	25
5.2.3 Bảng so sánh mô hình (CIFAR – Adam + Weight Decay)	26
5.3 Phân tích kết quả (CLO3)	26
5.3.1 Ưu điểm	26
5.3.2 Nhược điểm	27
5.3.3 Lỗi điển hình	27
5.4 Kết quả demo	27
5.4.1 Đối với dữ liệu Hazelnut	27
5.4.2 Đối với dữ liệu Bottle	28
5.4.3 Đối với dữ liệu CIFAR-10(one-class, airplane)	29
Chương 6 Kết luận và hướng phát triển	30
6.1 Kết luận	30
6.1.1 Kết quả chính	30
6.1.2 Đóng góp của đồ án	30
6.2 Hướng phát triển	31
Tài liệu tham khảo	32

Danh Sách Bảng

Bảng 1 . Bảng số tham số	15
Bảng 2 . Bảng so sánh Optimizer: Adam vs SGD(Hazelnut)	19
Bảng 3 . Bảng so sánh Regularization: Weight Decay vs Data Augmentation(Hazelnut)	19
Bảng 4 .Bảng so sánh Optimizer: Adam vs SGD (Bottle)	21
Bảng 5 . Bảng so sánh Regularization: Weight Decay vs Data Augmentation(Bottle)	21
Bảng 6 . Bảng so sánh Optimizer: Adam vs SGD (Cifar)	23
Bảng 7 .Bảng so sánh Regularization: Weight Decay vs Data Augmentation(Cifar)	23
Bảng 8 .Bảng so sánh 2 mô hình(Hazelnut)	25
Bảng 9 . Bảng so sánh 2 mô hình(Bottle)	25
Bảng 10 .Bảng so sánh 2 mô hình(Cifar)\	26

Danh Sách Hình

Hình 1 . Sơ đồ mô hình 1	15
Hình 2 . Sơ đồ mô hình nâng cao	17
Hình 3 . Biểu đồ Loss hazelnut_baseline_adam_weight_decay	17
Hình 4 . Biểu đồ Loss hazelnut_baseline_sgd_weight_decay	17
Hình 5 . Biểu đồ Loss hazelnut_baseline_adam_augmentation	18
Hình 6 . Biểu đồ Loss hazelnut_advanced_adam_weight_decay	18
Hình 7 . Biểu đồ Loss bottle_baseline_adam_augmentation	19
Hình 8 . Biểu đồ Loss bottle_baseline_adam_weight_decay	20
Hình 9 . Biểu đồ Loss bottle_advanced_adam_weight_decay	20
Hình 10 . Biểu đồ Loss bottle_baseline_sgd_weight_decay	20
Hình 11 . Biểu đồ Loss cifar_advanced_adam_weight_decay	22
Hình 12 . Biểu đồ Loss cifar_baseline_adam_augmentation	22
Hình 13 . Biểu đồ Loss cifar_baseline_adam_weight_decay	22
Hình 14 . Biểu đồ Loss cifar_baseline_sgd_weight_decay	22
Hình 15 . Demo hazelnut_basekine_adam_weight_decay	27
Hình 16 . Demo hazelnut_baseline_sgd_weight_decay	27
Hình 17 Demo hazelnut_baseline_adam_augmentation	28

Hình 18 . Demo hazelnut_advanced_adam_weight_decay	28
Hình 19 . Demo bottle_baseline_adam_weight_decay	28
Hình 20 Demo bottle_baseline_sgd_weight_decay	28
Hình 21 . Demo bottle_baseline_adam_augmentation	29
Hình 22 . Demo bottle_advanced_adam_weight_decay	29
Hình 23 Demo cifar_baseline_sgd_weight_decay	29
Hình 24 . Demo cifar_baseline_adam_weight_decay	29
Hình 25 Demo cifar_baseline_adam_augmentation	30
Hình 26 Demo cifar_advanced_adam_weight_decay	30

Chương 1 Giới thiệu

1.1 Bối cảnh và động cơ

1.1.1 Bối cảnh bài toán

Trong thực tế, việc phát hiện các lỗi hoặc dấu hiệu bất thường trong hình ảnh là một công việc xuất hiện rất nhiều trong đời sống. Chẳng hạn, trong các nhà máy sản xuất, công nhân phải kiểm tra từng sản phẩm để phát hiện các lỗi nhỏ như trầy xước, nứt hoặc sai hình dạng. Công việc này thường được thực hiện thủ công nên vừa tốn thời gian vừa dễ xảy ra sai sót, đặc biệt khi số lượng sản phẩm lớn. Tương tự, trong lĩnh vực y tế, bác sĩ cần quan sát các ảnh chụp như X-quang hoặc MRI để tìm ra các vùng bất thường, nhưng điều này đòi hỏi nhiều kinh nghiệm và vẫn có khả năng bỏ sót.

Một điểm đặc biệt là trong những tình huống này, dữ liệu bình thường thường chiếm phần lớn, còn các trường hợp bất thường lại rất ít và khó thu thập. Điều này gây khó khăn cho việc xây dựng các hệ thống tự động theo cách thông thường. Vì vậy, một hướng tiếp cận phù hợp là xây dựng mô hình học từ dữ liệu bình thường, sau đó phát hiện những điểm khác biệt khi gặp dữ liệu mới. Từ đó, bài toán phát hiện ảnh bất thường bằng học sâu được đặt ra nhằm giải quyết vấn đề này theo hướng tự động và hiệu quả hơn.

1.1.2 Động cơ bài toán

Bài toán phát hiện ảnh bất thường có ý nghĩa rất lớn trong nhiều lĩnh vực. Trong công nghiệp, việc áp dụng mô hình có thể giúp phát hiện lỗi sản phẩm ngay trên dây chuyền sản xuất mà không cần kiểm tra thủ công, từ đó giảm chi phí và nâng cao chất lượng sản phẩm. Trong y tế, hệ thống có thể hỗ trợ bác sĩ phát hiện sớm các dấu hiệu bất thường trong ảnh chụp, góp phần nâng cao hiệu quả chẩn đoán.

Ngoài ra, trong các hệ thống giám sát an ninh, việc phát hiện những hành vi hoặc đối tượng bất thường cũng giúp tăng khả năng cảnh báo sớm các tình huống nguy hiểm. Nhìn chung, việc ứng dụng bài toán này giúp tăng tính tự động, giảm phụ thuộc vào con người và nâng cao độ chính xác trong nhiều hệ thống thực tế.

Nhóm lựa chọn đề tài “Phát hiện ảnh bất thường” vì đây là một bài toán có tính ứng dụng cao và phù hợp với kiến thức đã học. Thứ nhất, đề tài gắn liền với các vấn đề thực tế nên giúp nhóm hiểu rõ hơn cách áp dụng học sâu vào đời sống. Thứ hai, bài toán phù hợp với các phương pháp học không giám sát như Autoencoder hoặc Variational Autoencoder, giúp nhóm có cơ hội tìm hiểu sâu hơn về cách mô hình học đặc trưng từ dữ liệu.

Bên cạnh đó, đề tài có thể triển khai theo nhiều mức độ từ cơ bản đến nâng cao, bắt đầu từ mô hình đơn giản rồi cải tiến dần. Việc sử dụng các bộ dữ liệu chuẩn như MVTec AD cũng giúp quá trình thực nghiệm rõ ràng và

dễ đánh giá. Thông qua đề tài này, nhóm mong muốn củng cố kiến thức, rèn luyện kỹ năng lập trình và hiểu rõ hơn về cách xây dựng cũng như đánh giá một hệ thống phát hiện bất thường trong thực tế.

1.2 Mục tiêu đồ án

Đồ án này tập trung vào bài toán phát hiện ảnh bất thường (anomaly detection) trong đó mô hình được huấn luyện chủ yếu trên dữ liệu ảnh bình thường và có nhiệm vụ phát hiện các mẫu khác biệt so với phân bố đã học. Các mục tiêu kỹ thuật của đồ án được xây dựng tương ứng với các chuẩn đầu ra CLO như sau:

1.2.1 (CLO1) Phân tích bài toán và thiết kế mô hình Deep Learning:

- Phân tích đặc điểm của bài toán phát hiện bất thường, trong đó dữ liệu huấn luyện chủ yếu là ảnh bình thường và không có hoặc rất ít mẫu bất thường.
- Tìm hiểu và mô tả đặc trưng của các dataset sử dụng (MVTec AD và CIFAR-10 one-class), bao gồm số lượng mẫu, sự mất cân bằng dữ liệu và các khó khăn như nhiễu hoặc khác biệt hình thái nhỏ giữa normal và anomaly.
- Thiết kế hướng tiếp cận dựa trên mô hình **Autoencoder**, trong đó sử dụng lỗi tái tạo (reconstruction error) làm cơ sở xây dựng anomaly score.
- Lựa chọn kiến trúc phù hợp với bài toán ảnh, cụ thể là **Convolutional Autoencoder** để khai thác thông tin không gian của ảnh.

1.2.2 (CLO2) – Triển khai và thực nghiệm

- Xây dựng đầy đủ pipeline cho bài toán phát hiện ảnh bất thường, bao gồm: đọc dữ liệu, tiền xử lý ảnh, resize ảnh về kích thước 256×256 , chuyển ảnh sang tensor, chia tập train/validation/test và huấn luyện mô hình bằng PyTorch.
- Triển khai ít nhất hai mô hình:
 - Mô hình cơ bản (baseline): Convolutional Autoencoder sử dụng reconstruction MSE.
 - Mô hình nâng cao (advanced): Denoising Attention Autoencoder, có thêm nhiễu Gaussian, Residual Block, SE Block và Attention nhằm cải thiện khả năng học đặc trưng của ảnh bình thường.
- Thực hiện các thí nghiệm so sánh giữa các mô hình, đồng thời khảo sát ảnh hưởng của các yếu tố như optimizer (SGD, Adam) và kỹ thuật regularization (weight decay, data augmentation).
- Xây dựng anomaly score dựa trên pixel reconstruction error, feature reconstruction error và combined score. Threshold được xác định từ kết quả đánh giá để phân loại ảnh thành normal hoặc anomaly.

1.2.3 (CLO3) – Đánh giá và vận dụng

- Đánh giá hiệu quả mô hình bằng các chỉ số định lượng như **AUROC** và **PR-AUC**, đồng thời phân tích sự khác biệt giữa pixel-level score và feature-level score.
- Trực quan hóa kết quả thông qua heatmap lỗi tái tạo để quan sát vị trí bất thường trên ảnh.
- Phân tích các trường hợp mô hình dự đoán sai để nhận diện hạn chế của phương pháp.
- Thảo luận khả năng ứng dụng của mô hình trong các bài toán thực tế như kiểm tra lỗi sản phẩm hoặc phát hiện bất thường trong dữ liệu hình ảnh công nghiệp.

1.3 Phạm vi và cấu trúc báo cáo

Đồ án tập trung vào bài toán phát hiện ảnh bất thường trong miền dữ liệu hình ảnh, với hướng tiếp cận chính là học từ dữ liệu bình thường và phát hiện các mẫu khác biệt. Phạm vi thực hiện được giới hạn trong các nội dung sau:

- Sử dụng dataset MVTec AD với 2 category cụ thể (hazelnut, bottle) và bổ sung bài toán one-class CIFAR-10 (airplane) để kiểm tra khả năng tổng quát của mô hình
- Ảnh đầu vào được chuẩn hóa về kích thước 256×256 để phù hợp với mô hình học sâu
- Triển khai hai mô hình chính:
 - Mô hình cơ bản: Convolutional Autoencoder.
 - Mô hình nâng cao: Denoising Autoencoder có thêm Attention, Residual Block và Gaussian Noise.
- Xây dựng anomaly score dựa trên:
 - Sai số tái tạo ở mức pixel (pixel MSE).
 - Sai số đặc trưng từ encoder (feature reconstruction).
 - Combined score giữa pixel score và feature score.
- Xác định ngưỡng phân loại từ tập validation (95%) để phân biệt ảnh bình thường và bất thường.
- Thực hiện các thí nghiệm so sánh giữa các mô hình: optimizer (SGD, Adam) và kỹ thuật regularization (weight decay, data augmentation)
- Trực quan hóa kết quả thông qua biểu đồ (learning curve, ROC, PR) và heatmap để hỗ trợ phân tích.
- Xây dựng một giao diện đơn giản để demo quá trình phát hiện bất thường trên ảnh đầu vào
- Đồ án không đi sâu vào việc tối ưu hóa kiến trúc ở mức nghiên cứu nâng cao hay đạt kết quả tốt nhất (SOTA), mà tập trung vào việc hiểu đúng bài toán, triển khai đầy đủ pipeline và đánh giá kết quả một cách hợp lý.

Chương 2 Cơ sở lý thuyết và nghiên cứu liên quan

2.1 Kiến thức nền tảng

2.1.1 Tổng quan về Deep Learning

- Theo Goodfellow et al. [1]: “Deep learning allows computational models that are composed of multiple processing layers to learn representations of data with multiple levels of abstraction.”
- Điều này cho thấy CNN đặc biệt phù hợp với dữ liệu hình ảnh do có khả năng xử lý thông tin không gian. Ngoài ra, Krizhevsky et al. [3] cũng chỉ ra rằng CNN có hiệu quả rất cao trong các bài toán thị giác máy tính.
- Trong đồ án, CNN được sử dụng trong Autoencoder để học đặc trưng của ảnh và phục vụ cho việc tái tạo ảnh đầu vào.

2.1.2 Convolutional Neural Network (CNN)

- Theo LeCun et al. [2]: “Convolutional networks are designed to process data that come in the form of multiple arrays, for example a color image composed of three 2D arrays.”
- Điều này cho thấy CNN đặc biệt phù hợp với dữ liệu hình ảnh do có khả năng xử lý thông tin không gian. Ngoài ra, Krizhevsky et al. [3] cũng chỉ ra rằng CNN có hiệu quả rất cao trong các bài toán thị giác máy tính.
- Trong đồ án, CNN được sử dụng trong Autoencoder để học đặc trưng của ảnh và phục vụ cho việc tái tạo ảnh đầu vào.

2.1.3 Autoencoder

- Theo Hinton và Salakhutdinov [4]: “An autoencoder is a neural network that is trained to attempt to copy its input to its output.”
- Từ định nghĩa này, Autoencoder có thể hiểu là mô hình học cách tái tạo lại dữ liệu đầu vào thông qua một biểu diễn trung gian. Trong bài toán anomaly detection, mô hình được huấn luyện trên dữ liệu bình thường, do đó khi gặp dữ liệu bất thường, sai số tái tạo sẽ tăng lên và được dùng làm cơ sở phát hiện anomaly.

2.1.4 Denoising Autoencoder

- Theo Vincent et al. [5]: “Denoising autoencoders are trained to reconstruct a clean input from a corrupted version of it.”
- Điều này có nghĩa là mô hình học cách khôi phục dữ liệu gốc từ dữ liệu bị nhiễu. Cách tiếp cận này giúp mô hình học được các đặc trưng ổn định hơn và tăng khả năng tổng quát hóa. Trong đồ án, Denoising Autoencoder được sử dụng như một mô hình nâng cao để cải thiện hiệu quả phát hiện bất thường.

2.1.5 Recurrent Neural Network (RNN) và LSTM

- Theo Hochreiter và Schmidhuber [6]: “Long Short-Term Memory is designed to overcome the vanishing gradient problem.”
- Như vậy, LSTM được thiết kế để giải quyết vấn đề suy giảm gradient trong RNN truyền thống, giúp mô hình học được các phụ thuộc dài hạn trong dữ liệu chuỗi. Tuy nhiên, trong phạm vi đề án này, RNN và LSTM không được áp dụng do dữ liệu là ảnh tĩnh.

2.1.6 Transformer

- Theo Vaswani et al. [7]: “The Transformer model relies entirely on attention mechanisms to draw global dependencies between input and output.”
- Transformer sử dụng cơ chế attention để học mối quan hệ giữa các phần của dữ liệu mà không cần xử lý tuần tự. Mặc dù rất mạnh, nhưng mô hình này không được sử dụng trong đề án do yêu cầu tập trung vào các mô hình cơ bản như Autoencoder.

2.1.7 Chỉ số đánh giá

- Trong bài toán anomaly detection, việc đánh giá mô hình không chỉ dựa vào độ chính xác mà cần sử dụng các chỉ số phù hợp với dữ liệu mất cân bằng.
 - AUROC giúp đánh giá khả năng phân biệt giữa hai lớp
 - PR-AUC phù hợp khi số lượng mẫu anomaly ít hơn nhiều so với normal
- Các chỉ số này được sử dụng trong đề án để so sánh hiệu quả giữa các mô hình.

2.2 Các nghiên cứu hoặc mô hình liên quan

Trong bài toán phát hiện ảnh bất thường, hướng tiếp cận phổ biến là học từ dữ liệu bình thường để phát hiện sự khác biệt khi gặp dữ liệu mới.

Một phương pháp được sử dụng nhiều là Autoencoder. Mô hình học cách tái tạo lại ảnh đầu vào, nên khi gặp ảnh bất thường thì reconstruction error thường sẽ cao hơn ảnh bình thường.

Ngoài ra, Denoising Autoencoder được dùng để cải thiện khả năng học đặc trưng bằng cách thêm nhiễu vào ảnh đầu vào và yêu cầu mô hình khôi phục lại ảnh gốc. Cách này giúp mô hình tổng quát tốt hơn và giảm overfitting.

Bên cạnh pixel reconstruction error, nhiều nghiên cứu còn sử dụng feature reconstruction error từ encoder để phát hiện các anomaly nhỏ hoặc khó nhận biết. Trong đề án này, nhóm kết hợp pixel score và feature score để xây dựng anomaly score.

Một số phương pháp hiện đại hơn như GAN hoặc Transformer cũng được áp dụng trong anomaly detection, tuy nhiên các mô hình này phức tạp hơn và yêu cầu tài nguyên tính toán lớn.

Trong phạm vi đề án, nhóm lựa chọn hướng tiếp cận dựa trên Autoencoder vì phù hợp với yêu cầu đề tài, dễ triển khai và cho kết quả ổn định trên dataset MVTec AD và CIFAR-10 one-class.

Chương 3 Bài toán và dữ liệu

3.1 Mô tả bài toán

3.1.1 Đầu vào (Input)

Đầu vào của hệ thống là ảnh màu từ dataset MVTec AD gồm hai category hazelnut, bottle và dataset CIFAR-10 one-class với lớp airplane làm lớp normal. Tất cả ảnh được tiền xử lý trước khi đưa vào mô hình, gồm resize về kích thước 256×256 , chuyển sang tensor và chuẩn hóa giá trị pixel về khoảng $[0,1]$.

Trong quá trình huấn luyện, mô hình chủ yếu sử dụng ảnh bình thường để học đặc trưng của dữ liệu normal, phù hợp với bài toán anomaly detection khi dữ liệu lỗi thường ít và khó thu thập.

3.1.2 Đầu ra (Output)

Đầu ra của mô hình gồm hai thành phần chính:

- Anomaly score: thể hiện mức độ bất thường của ảnh, được tính từ pixel reconstruction error, feature reconstruction error và combined score.
- Nhãn phân loại (normal/anomaly): Dựa trên anomaly score và một ngưỡng (threshold) được xác định từ tập validation, ảnh sẽ được phân loại thành:
 - Bình thường (normal)
 - Bất thường (anomaly)

3.1.3 Giả định và ràng buộc

Đề án được thực hiện với một số giả định và ràng buộc như sau:

- Giả định:
 - Dữ liệu huấn luyện chỉ bao gồm ảnh bình thường, do đó mô hình học được đặc trưng của phân bố normal.
 - Ảnh bất thường sẽ có sự khác biệt đủ lớn so với ảnh bình thường, dẫn đến sai số tái tạo cao hơn.
 - Kích thước ảnh được chuẩn hóa về cùng một dạng (256×256) để đảm bảo tính nhất quán khi đưa vào mô hình.
- Ràng buộc:
 - Dataset bị mất cân bằng (ít anomaly hơn normal), ảnh hưởng đến việc đánh giá mô hình.
 - Một số lỗi trong ảnh (defect) có thể rất nhỏ hoặc khó nhận biết, khiến mô hình khó phát hiện chính xác.

- Việc resize ảnh từ CIFAR (32×32 lên 256×256) có thể làm mất chi tiết, ảnh hưởng đến chất lượng đặc trưng.
- Mô hình sử dụng Autoencoder phụ thuộc vào khả năng tái tạo ảnh; nếu mô hình tái tạo tốt cả vùng lỗi thì anomaly score có thể không đủ cao để phân loại chính xác.

3.2 Dataset

3.2.1 Nguồn dữ liệu

Trong đồ án này, dữ liệu được sử dụng từ hai nguồn chính là MVTec AD và CIFAR-10 (one-class) nhằm phục vụ cho bài toán phát hiện ảnh bất thường.

Tất cả ảnh đầu vào đều được resize về kích thước 256×256 và chuẩn hóa trước khi đưa vào mô hình. Dữ liệu được chia thành ba tập: train, validation và test. Trong đó:

Đối với dataset MVTec AD, đây là bộ dữ liệu phổ biến trong bài toán anomaly detection trong lĩnh vực công nghiệp. Dataset bao gồm nhiều loại sản phẩm khác nhau với các lỗi (defect) cụ thể. Trong phạm vi đồ án, hai category được sử dụng là hazelnut và bottle.

- Đối với category hazelnut:
 - Tập train chỉ chứa ảnh bình thường: 391 ảnh
 - Tập test chứa ảnh bình thường và ảnh bất thường: 110 ảnh
 - Validation: trích từ train để chọn threshold
 - Đối với category bottle:
 - Tập train chỉ chứa ảnh bình thường: 209 ảnh
 - Tập test chứa ảnh bình thường và ảnh bất thường: 83 ảnh
 - Validation: trích từ train để chọn threshold
- Đối với dataset CIFAR-10 theo hướng one-class (tùy chọn) để tăng tính đa dạng cho thí nghiệm. Cụ thể, một lớp được chọn làm lớp bình thường (ví dụ: airplane), các lớp còn lại được xem là bất thường. Tuy nhiên, do ảnh CIFAR-10 có kích thước gốc nhỏ (32×32), nên cần resize lên 256×256 để phù hợp với mô hình. Việc này có thể làm giảm chất lượng chi tiết ảnh và khiến bài toán trở nên khó hơn.
- Tập train chỉ chứa ảnh airplan: 5000 ảnh
 - Tập test chứa tất cả: 10000 ảnh
 - Validation: trích từ train để chọn threshold
- Một số khó khăn chính của dữ liệu:
 - Mất cân bằng dữ liệu (train chỉ có normal)
 - Lỗi bất thường thường nhỏ, khó nhận biết
 - Một số lỗi có đặc điểm gần giống bình thường
 - CIFAR bị mất chi tiết khi resize

Nhìn chung, việc lựa chọn kết hợp MVTEC AD và CIFAR-10 giúp đánh giá mô hình trong cả bối cảnh dữ liệu công nghiệp (rõ lỗi) và dữ liệu tự nhiên (khó phân biệt hơn).

3.2.2 Tiền xử lý dữ liệu

3.2.2.1 Chuẩn hóa dữ liệu

Tất cả ảnh đầu vào từ các dataset đều được resize về cùng kích thước 256×256 để đảm bảo tính đồng nhất khi đưa vào mô hình. Sau đó, ảnh được chuyển về dạng tensor và chuẩn hóa giá trị pixel về khoảng $[0,1]$.

Việc chuẩn hóa dữ liệu giúp quá trình huấn luyện ổn định hơn và giúp mô hình học đặc trưng ảnh hiệu quả hơn.

3.2.2.2 Tăng cường dữ liệu (Data Augmentation)

Để tăng khả năng tổng quát hóa của mô hình, một số kỹ thuật tăng cường dữ liệu được áp dụng trên tập train (chỉ gồm ảnh bình thường), bao gồm:

- Lật ngang ngẫu nhiên (Random Horizontal Flip)
- Lật dọc ngẫu nhiên (Random Vertical Flip)
- Xoay nhẹ (Random Rotation)
- Thay đổi độ sáng, tương phản và màu sắc (Color Jitter)

Các phép biến đổi này giúp mô hình học được nhiều biến thể khác nhau của dữ liệu bình thường, từ đó cải thiện khả năng phát hiện bất thường trên ảnh mới.

3.2.2.3 Xử lý mất cân bằng dữ liệu

Đặc trưng của bài toán anomaly detection là dữ liệu bị mất cân bằng nghiêm trọng:

- Tập train chỉ chứa ảnh normal
- Tập test mới có cả normal và anomaly

Trong đề án này, nhóm không sử dụng các kỹ thuật cân bằng dữ liệu như oversampling hoặc undersampling, mà giữ nguyên hướng tiếp cận one-class anomaly detection. Mô hình được huấn luyện trên dữ liệu bình thường để học đặc trưng tái tạo của ảnh normal.

Để phân loại ảnh, nhóm sử dụng anomaly score được xây dựng từ pixel reconstruction error, feature reconstruction error và combined score. Threshold được xác định từ tập validation để phân biệt ảnh normal và anomaly.

Cách tiếp cận này phù hợp với thực tế vì dữ liệu lỗi thường hiếm và khó thu thập.

Chương 4 Phương pháp đề xuất

4.1 Mô hình 1 (Baseline)

Trong đề án này, mô hình baseline được lựa chọn là Convolutional Autoencoder (CAE). Đây là một kiến trúc phổ biến trong bài toán phát hiện bất thường dựa trên reconstruction.

4.1.1 Ý tưởng mô hình

Mô hình được huấn luyện chỉ với ảnh bình thường (normal), nhằm học cách tái tạo lại ảnh đầu vào. Khi đưa vào một ảnh bất thường, mô hình sẽ tái tạo kém hơn ở các vùng lỗi, dẫn đến sai số tái tạo (reconstruction error) cao. Sai số này được sử dụng làm anomaly score để phân loại.

4.2.2 Kiến trúc mô hình

Mô hình gồm hai phần chính: encoder và decoder.

- Encoder: trích xuất đặc trưng và giảm kích thước ảnh
- Decoder: tái tạo lại ảnh từ đặc trưng đã nén

Cụ thể kiến trúc như sau:

– Encoder:

- Conv2D ($3 \rightarrow 32$), kernel 3×3 , stride 2, padding 1 + BatchNorm + LeakyReLU
- Conv2D ($32 \rightarrow 64$), stride 2 + BatchNorm + LeakyReLU
- Conv2D ($64 \rightarrow 128$), stride 2 + BatchNorm + LeakyReLU
- Conv2D ($128 \rightarrow 256$), stride 2 + BatchNorm + LeakyReLU

Sau encoder, ảnh đầu vào kích thước 256×256 sẽ được giảm xuống còn $16 \times 16 \times 256$.

– Decoder:

- ConvTranspose2D ($256 \rightarrow 128$), stride 2 + BatchNorm + ReLU
- ConvTranspose2D ($128 \rightarrow 64$), stride 2 + BatchNorm + ReLU
- ConvTranspose2D ($64 \rightarrow 32$), stride 2 + BatchNorm + ReLU
- ConvTranspose2D ($32 \rightarrow 3$), stride 2 + Sigmoid

Đầu ra của decoder có cùng kích thước với ảnh đầu vào ($256 \times 256 \times 3$), với giá trị nằm trong khoảng $[0, 1]$.

4.1.3 Số tham số


Lớp	Input → Output	Tính	Số tham số
-----	-------------------	------	------------

Encoder			
Conv2d + BN	$3 \rightarrow 32$	$3 \times 32 \times 3 \times 3 + 32$	960
Conv2d + BN	$32 \rightarrow 64$	$32 \times 64 \times 3 \times 3 + 64$	18,624
Conv2d + BN	$64 \rightarrow 128$	$64 \times 128 \times 3 \times 3 + 128$	74,112
Conv2d + BN	$128 \rightarrow 256$	$128 \times 256 \times 3 \times 3 + 256$	295,680
Decoder			
ConvTranspose2d + BN	$256 \rightarrow 128$	$256 \times 128 \times 3 \times 3 + 128$	295,296
ConvTranspose2d + BN	$128 \rightarrow 64$	$128 \times 64 \times 3 \times 3 + 64$	73,920
ConvTranspose2d + BN	$64 \rightarrow 32$	$64 \times 32 \times 3 \times 3 + 32$	18,528
ConvTranspose2d	$32 \rightarrow 3$	$32 \times 3 \times 3 \times 3 + 3$	867
Tổng			776,987

Bảng 1. Bảng số tham số

Bảng 1 trình bày chi tiết số lượng tham số của từng lớp trong mô hình ConvAutoEncoder. Tổng số tham số của mô hình khoảng 0.78 triệu, cho thấy mô hình có độ phức tạp trung bình, phù hợp với bài toán phát hiện bất thường trên ảnh kích thước 256×256 .

4.1.4 Sơ đồ mô hình



Hình 1. Sơ đồ mô hình 1

4.2 Mô hình 2 (Nâng cao)

4.2.1 Kiến trúc mô hình nâng cao

Trong đề án này, mô hình nâng cao được xây dựng dựa trên Denoising Attention Autoencoder nhằm cải thiện khả năng phát hiện bất thường so với mô hình baseline.

Kiến trúc mô hình vẫn giữ dạng Encoder – Decoder, bao gồm:

- Encoder: sử dụng các lớp Conv2D kết hợp với Batch Normalization, LeakyReLU, Residual Block và SE Block để trích xuất đặc trưng ảnh và giảm kích thước dữ liệu.
- Decoder: gồm các lớp ConvolutionTranspose để tái tạo lại ảnh từ vector đặc trưng đã mã hóa.

Ngoài ra, mô hình còn bổ sung Bottleneck Self-Attention ở phần latent feature nhằm tăng khả năng học mối quan hệ đặc trưng trong ảnh.

Điểm khác biệt chính của mô hình nâng cao là:

- Trong quá trình huấn luyện, ảnh đầu vào được thêm nhiễu Gaussian với độ lệch chuẩn nhỏ.
- Mô hình học cách khôi phục ảnh gốc từ ảnh bị nhiễu, thay vì chỉ học sao chép dữ liệu.
- Sử dụng thêm Attention và Residual Block để cải thiện khả năng học đặc trưng và tăng tính tổng quát hóa.

Cách tiếp cận này giúp mô hình học được biểu diễn ổn định hơn và hỗ trợ phát hiện anomaly tốt hơn trên một số trường hợp khó.

4.2.2 Phương pháp đánh giá bất thường


Mô hình sử dụng 3 cách tính điểm bất thường:

- Pixel Reconstruction Error (MSE): là sai số giữa ảnh gốc và ảnh tái tạo trên từng pixel. Khi ảnh chứa anomaly, mô hình thường tái tạo kém hơn nên reconstruction error sẽ cao hơn.
- Feature Reconstruction Error: Thay vì so sánh trực tiếp trên ảnh, phương pháp này so sánh đặc trưng trích xuất từ encoder của ảnh gốc và ảnh tái tạo. Điều này giúp phát hiện các bất thường về cấu trúc và ngữ nghĩa.
- Combined Score: kết hợp pixel score và feature score theo trọng số để tăng khả năng phân biệt giữa ảnh normal và anomaly.

4.2.3 Kỳ vọng cải thiện

- Tăng khả năng tổng quát hóa nhờ cơ chế denoising và attention, giúp mô hình không phụ thuộc quá nhiều vào dữ liệu train.
 - Giảm overfitting khi dữ liệu huấn luyện chủ yếu chỉ gồm ảnh normal.
 - Phát hiện tốt hơn các bất thường nhỏ hoặc khó nhận biết
 - Cải thiện độ chính xác (AUROC, PR-AUC) trong các thí nghiệm
- Đặc biệt, việc kết hợp giữa pixel reconstruction error và feature reconstruction error giúp mô hình vừa phát hiện được lỗi bề mặt, vừa nhận diện được các bất thường về cấu trúc và đặc trưng ảnh.


4.2.4 Sơ đồ mô hình 2




Hình 2. Sơ đồ mô hình nâng cao

4.3 Hàm mất mát và thuật toán tối ưu


4.3.1 Đối với dữ liệu Hazelnut




Hình 3. Biểu đồ Loss hazelnut_baseline_adam_weight_decay



Hình 4. Biểu đồ Loss hazelnut_baseline_sgd_weight_decay



Hình 5. Biểu đồ Loss hazelnut_baseline_adam_augmentation



Hình 6. Biểu đồ Loss hazelnut_advanced_adam_weight_decay

Nhận xét chung

- Train loss và validation loss đều giảm mạnh ở những epoch đầu, sau đó giảm chậm dần và ổn định hơn về cuối quá trình huấn luyện.
- Khoảng cách giữa train loss và validation loss khá nhỏ, cho thấy mô hình không bị overfitting rõ rệt.
- Với Adam: loss giảm rất nhanh chỉ sau vài epoch đầu, giá trị loss cuối rất thấp và hội tụ ổn định.
- Với SGD: loss giảm chậm hơn nhiều, sau 30 epoch loss vẫn còn khá cao và có dấu hiệu underfitting.

→ Adam phù hợp hơn cho bài toán anomaly detection trên hazelnut vì hội tụ nhanh và đạt loss thấp hơn đáng kể so với SGD.

So sánh Optimizer: Adam vs SGD

Tiêu chí	Adam	SGD
Tốc độ giảm loss	Rất nhanh	Chậm
Tốc độ hội tụ	Hội tụ nhanh	Chưa hội tụ tốt
Giá trị loss cuối	~0.0005 – 0.002	~0.048 – 0.05
Độ ổn định	Ổn định, giao động nhẹ	Ổn định nhưng giảm

		chậm
Hiệu quả tổng thể	Tốt	Kém hơn trong bài này

Bảng 2. Bảng so sánh Optimizer: Adam vs SGD(Hazelnut)

Adam cho kết quả tốt hơn rõ rệt so với SGD. SGD giảm loss chậm và cần nhiều epoch hơn để đạt kết quả tương đương.


So sánh regularization: Weight Decay và Data Augmentation

Tiêu chí	Weight Decay	Data Augmentation
Tốc độ hội tụ	Nhanh	Nhanh
Độ ổn định	Rất ổn định	Dao động nhẹ
Validation loss	Thấp và ổn định	Thấp nhưng hơi nhiễu
Khả năng tổng quát	Tốt	Tốt hơn
Phù hợp bài toán	Khá tốt	Rất phù hợp


Bảng 3. Bảng so sánh Regularization: Weight Decay vs Data Augmentation(Hazelnut)

→ Data Augmentation giúp mô hình học được nhiều biến thể của ảnh normal nên khả năng tổng quát hóa tốt hơn. Weight Decay giúp quá trình huấn luyện ổn định và giảm overfitting hiệu quả.


4.3.2 Đối với dữ liệu Bottle




Hình 7. Biểu đồ Loss bottle_baseline_adam_augmentation



Hình 8. Biểu đồ Loss bottle_baseline_adam_weight_decay



Hình 9. Biểu đồ Los bottle_advanced_adam_weight_decay



Hình 10. Biểu đồ Loss bottle_baseline_sgd_weight_decay

Nhận xét chung:

- Train loss và validation loss giảm mạnh ở những epoch đầu, sau đó giảm chậm dần và ổn định hơn về cuối quá trình huấn luyện.
- Hai đường train loss và validation loss khá gần nhau, cho thấy mô hình không bị overfitting rõ rệt.
- Với Adam: mô hình hội tụ nhanh, loss giảm mạnh chỉ sau vài epoch đầu và

đạt giá trị rất thấp.

- Với SGD: loss giảm chậm hơn nhiều và vẫn còn khá cao sau 30 epoch.
→ Adam cho kết quả tốt hơn SGD trên dataset Bottle vì hội tụ nhanh và ổn định hơn.

So sánh Optimizer: Adam vs SGD

Tiêu chí	Adam	SGD
Tốc độ hội tụ	Nhanh	Chậm
Mức giảm loss	Giảm rất nhanh	Giảm chậm
Giá trị loss cuối	Rất thấp ($\sim 0.001 - 0.003$)	Còn khá cao (~ 0.136)
Độ ổn định	Ổn định	Ổn định nhưng học chậm
Khả năng học	Học tốt đặc trưng dữ liệu	Chưa học tốt
Kết quả trên Bottle	Tốt hơn	Kém hơn

Bảng 4. Bảng so sánh Optimizer: Adam vs SGD (Bottle)

→ Adam cho kết quả tốt hơn rõ rệt trên dataset Bottle nhờ khả năng hội tụ nhanh và đạt loss thấp hơn SGD.


So sánh regularization: Weight Decay và Data Augmentation

Tiêu chí	Weight Decay	Data Augmentation
Tác động	Lên trọng số mô hình	Lên dữ liệu đầu vào
Độ ổn định	Mượt và ổn định	Dao động nhẹ
Validation loss	Ổn định	Thấp hơn
Khả năng giảm overfitting	Trung bình	Tốt
Khả năng tổng quát	Khá	Tốt hơn


Bảng 5. Bảng so sánh Regularization: Weight Decay vs Data Augmentation (Bottle)

→ Data Augmentation giúp mô hình học được nhiều biến thể dữ liệu hơn nên khả năng tổng quát hóa tốt hơn Weight Decay, dù validation loss có dao động nhẹ.


4.3.3 Đối với dữ liệu CIFAR-10 (one-class)




Hình 11. Biểu đồ Loss cifar_advanced_adam_weight_decay



Hình 12. Biểu đồ Loss cifar_baseline_adam_augmentation



Hình 13. Biểu đồ Loss cifar_baseline_adam_weight_decay



Hình 14. Biểu đồ Loss cifar_baseline_sgd_weight_decay

Nhận xét chung:

- Train loss và validation loss giảm nhanh ở những epoch đầu, sau đó giảm chậm dần và ổn định hơn.
- Khoảng cách giữa train loss và validation loss tương đối nhỏ, cho thấy mô hình không bị overfitting rõ rệt.

- Với Adam: mô hình hội tụ nhanh, loss thấp nhưng validation loss có dao động nhẹ ở một số epoch.
- Với SGD: loss giảm chậm hơn đáng kể và giá trị loss cuối vẫn còn khá cao.
→ Adam phù hợp hơn cho CIFAR-10 vì hội tụ nhanh và đạt loss thấp hơn so với SGD.

So sánh Optimizer: Adam vs SGD

Tiêu chí	Adam	SGD
Tốc độ giảm loss	Rất nhanh	Chậm
Giá trị loss cuối	$\sim 0.001 - 0.007$	$\sim 0.007 - 0.008$
Độ ổn định	Khá ổn định, dao động nhẹ	Ổn định nhưng giảm chậm
Hội tụ	Hội tụ nhanh	Chưa hội tụ tốt
Hiệu quả tổng thể	Tốt	Kém hơn

Bảng 6. Bảng so sánh Optimizer: Adam vs SGD (Cifar)

→ Adam cho kết quả tốt hơn trên CIFAR-10 nhờ tốc độ hội tụ nhanh và loss thấp hơn SGD.

So sánh regularization: Weight Decay và Data Augmentation

Tiêu chí	Weight Decay	Data Augmentation
Loss ban đầu	Cao hơn	Thấp hơn
Tốc độ hội tụ	Nhanh	Nhanh
Độ ổn định	Ổn định	Dao động nhẹ
Validation loss	Ổn định, thấp	Thấp nhưng hơi nhiễu
Khả năng tổng quát	Tốt	Tốt hơn
Phù hợp bài toán	Khá tốt	Rất phù hợp

Bảng 7. Bảng so sánh Regularization: Weight Decay vs Data Augmentation (Cifar)

→ Data Augmentation giúp mô hình học được nhiều biến thể dữ liệu hơn nên khả năng tổng quát hóa tốt hơn, tuy nhiên validation loss có dao động nhẹ hơn so với Weight Decay.

Chương 5 Thực nghiệm và đánh giá

5.1 Thiết lập thí nghiệm

5.1.1 Môi trường thực nghiệm

Bài toán được cài đặt bằng Python và PyTorch để xây dựng và huấn luyện mô hình Deep Learning. Ngoài ra còn sử dụng OpenCV để xử lý ảnh, NumPy để thao tác dữ liệu, Matplotlib để vẽ biểu đồ, scikit-learn để tính

metric và Torchvision để hỗ trợ transform ảnh. Giao diện demo được xây dựng bằng PyQt6 để hiển thị ảnh tái tạo, heatmap lỗi và anomaly score.

5.1.2 Phần cứng sử dụng

Chương trình hỗ trợ chạy trên cả GPU và CPU. Trong code, thiết bị xử lý được tự động lựa chọn bằng lệnh:

```
DEVICE = torch.device("cuda" if torch.cuda.is_available() else "cpu")
```

Nếu máy có GPU CUDA thì mô hình sẽ train bằng GPU để tăng tốc, ngược lại sẽ chạy bằng CPU.

5.1.3 Siêu tham số sử dụng

- Kích thước ảnh đầu vào: 256 x 256
- Batch size: 16
- Số epoch: 30
- Learning rate: 1e-3
- Seed cố định: 42 để đảm bảo kết quả có thể lặp lại
- weight decay = 1e-4 trong một số thí nghiệm regularization
- momentum = 0.9 đối với optimizer SGD
- noise_std = 0.05 đối với mô hình Denoising AutoEncoder

5.2 Kết quả định lượng

Nhận xét chung:

- MVTec có defect nhỏ, mờ, phản xạ
- CIFAR one-class khó hơn nhiều
- resize CIFAR 32x32 lên 256 làm mờ chi tiết.

Các dữ liệu này khiến:

- Mô hình baseline đơn giản học được đặc trưng chính của dữ liệu ổn định hơn.
- Mô hình advanced có kiến trúc phức tạp hơn nên dễ học đặc trưng quá tổng quát.
- Mô hình 2 có khả năng tái tạo ảnh và feature tốt hơn, tuy nhiên lại chưa làm nổi bật vùng bất thường. Khi mô hình tái tạo cả vùng lỗi quá giống ảnh gốc thì anomaly score giữa ảnh normal và anomaly sẽ giảm, dẫn đến khả năng phát hiện bất thường kém hơn.
- Trong bài toán anomaly detection, mục tiêu chính là phát hiện bất thường chứ không phải tái tạo ảnh đẹp. Vì vậy mô hình được đánh giá chủ yếu dựa trên AUROC và PR-AUC thay vì chỉ dựa vào reconstruction loss.

- Kết quả thực nghiệm cho thấy dù mô hình advanced có reconstruction loss thấp hơn, mô hình baseline vẫn cho khả năng phát hiện bất thường tốt hơn trên nhiều dataset.

5.2.1 Bảng so sánh mô hình (Hazelnut – Adam + Weight Decay)

Tiêu chí	Baseline(Mô hình 1)	Advanced(Mô hình 2)
Số tham số	776987	2906336
Threshold pixel	0,000789	0,000831
Threshold feature	0,008572	0.009459
AUROC pixel	0.8939	0.7188
PR-AUC pixel	0.9433	0.8576
AUROC feature	0.8938	0.7047
PR-AUC feature	0.9396	0.8415
Val_loss_last	0,001375	0,00139
Train_loss_last	0,000361	0,0216

Bảng 8. Bảng so sánh 2 mô hình(Hazelnut)

- Baseline cho kết quả tốt hơn Advanced ở cả pixel-level và feature-level với AUROC và PR-AUC cao hơn.
- Dù Advanced có nhiều tham số hơn và kiến trúc phức tạp hơn, khả năng phát hiện bất thường vẫn kém hơn Baseline trên dataset Hazelnut.
- Train loss và val loss của Baseline thấp và ổn định hơn, cho thấy mô hình học tốt hơn trong quá trình huấn luyện.
- Kết quả cho thấy mô hình AutoEncoder đơn giản phù hợp hơn với bài toán anomaly detection trong trường hợp này.

5.2.2 Bảng so sánh mô hình (Bottle – Adam + Weight Decay)

Tiêu chí	Baseline(Mô hình 1)	Advanced(Mô hình 2)
Số tham số	777987	2906336
Threshold pixel	0,001928	0,00328
Threshold feature	0,003177	0.01046
AUROC pixel	0.48889	0.6944
PR-AUC pixel	0.8052	0.8993
AUROC feature	0.5103	0.877
PR-AUC feature	0.7895	0.957
Train_loss_last	0,00103	0,0387
Val_loss_last	0,00379	0,00291

Bảng 9. Bảng so sánh 2 mô hình(Bottle)

- Trên dataset Bottle, mô hình Advanced cho kết quả tốt hơn Baseline ở cả pixel-level và feature-level với AUROC và PR-AUC cao hơn rõ rệt.
- Dù có số lượng tham số lớn hơn và train loss cao hơn, Advanced vẫn cho khả năng phát hiện bất thường hiệu quả hơn Baseline.
- Baseline cho kết quả khá thấp, đặc biệt AUROC gần 0.5, cho thấy mô hình chưa học được đặc trưng bất thường tốt.
- Kết quả cho thấy kiến trúc nâng cao phù hợp hơn với dataset này và giúp cải thiện khả năng anomaly detection.

5.2.3 Bảng so sánh mô hình (CIFAR – Adam + Weight Decay)

Tiêu chí	Baseline(Mô hình 1)	Advanced(Mô hình 2)
Số tham số	777987	2906336
Threshold pixel	0,00264	0,00265
Threshold feature	1,693	0.003369
AUROC pixel	0.6489	0.6047
PR-AUC pixel	0.9353	0.9275
AUROC feature	0.6631	0.7784
PR-AUC feature	0.9325	0.9638
Train_loss_last	0,001637	0,00715
Val_loss_last	0,001107	0,00092

Bảng 10. Bảng so sánh 2 mô hình (Cifar)\

- Trên CIFAR, Baseline cho kết quả tốt hơn ở pixel-level với AUROC và PR-AUC cao hơn mô hình Advanced.
- Ngược lại, Advanced cho kết quả tốt hơn ở feature-level, đặc biệt AUROC feature và PR-AUC feature tăng khá rõ.
- Advanced có val loss thấp hơn, cho thấy khả năng tái tạo và học đặc trưng dữ liệu tốt hơn Baseline.
- Kết quả cho thấy mỗi mô hình có ưu điểm riêng: Baseline phù hợp hơn với pixel reconstruction, còn Advanced hiệu quả hơn khi sử dụng feature reconstruction để phát hiện bất thường.

5.3 Phân tích kết quả (CLO3)

5.3.1 Ưu điểm

- Xây dựng đầy đủ pipeline anomaly detection từ xử lý dữ liệu đến đánh giá.
- Có so sánh 2 mô hình Deep Learning: baseline và advanced.
- Có so sánh optimizer và regularization đúng yêu cầu đề.
- Có sử dụng learning curves, ROC, PR curve và heatmap.

- GUI hỗ trợ quan sát trực quan kết quả phát hiện bất thường.

5.3.2 Nhược điểm

- Mô hình còn khá đơn giản nên chưa phát hiện tốt anomaly phức tạp.
- Advanced model khó train hơn và chưa luôn tốt hơn baseline.
- CIFAR cho kết quả thấp do dữ liệu khó và ảnh nhỏ.
- Chưa tối ưu nhiều siêu tham số.

5.3.3 Lỗi điển hình


- Underfitting khi dùng SGD.
- Bỏ sót anomaly nhỏ hoặc mờ.
- Resize CIFAR từ 32x32 lên 256x256 làm mất chi tiết.
- Denoising model thêm noise nên khó học hơn.

5.4 Kết quả demo


5.4.1 Đối với dữ liệu Hazelnut




Hình 15. Demo hazelnut_basekine_adam_weight_decay



Hình 16. Demo hazelnut_baseline_sgd_weight_decay



Hình 17 Demo hazelnut_baseline_adam_augmentation




Hình 18. Demo hazelnut_advanced_adam_weight_decay

5.4.2 Đối với dữ liệu Bottle



Hình 19. Demo bottle_baseline_adam_weight_decay



Hình 20 Demo bottle_baseline_sgd_weight_decay




Hình 21. Demo bottle_baseline_adam_augmentation




Hình 22. Demo bottle_advanced_adam_weight_decay

5.4.3 Đối với dữ liệu CIFAR-10(one-class, airplane)



Hình 23 Demo cifar_baseline_sgd_weight_decay



Hình 24. Demo cifar_baseline_adam_weight_decay



Hình 25 Demo cifar_baseline_adam_augmentation



Hình 26 Demo cifar_advanced_adam_weight_decay

Chương 6 Kết luận và hướng phát triển

6.1 Kết luận

6.1.1 Kết quả chính

Trong đồ án này, nhóm đã xây dựng hệ thống phát hiện bất thường dựa trên Convolutional AutoEncoder và Denoising Attention AutoEncoder.

Kết quả thực nghiệm cho thấy:

- Baseline hoạt động ổn định và cho kết quả tốt trên nhiều dataset.
 - Adam hiệu quả hơn SGD do hội tụ nhanh hơn.
 - Data Augmentation giúp cải thiện khả năng tổng quát.
 - Một số trường hợp mô hình đơn giản cho kết quả tốt hơn mô hình phức tạp.
- Learning curves cho thấy mô hình hội tụ ổn định và không bị overfitting mạnh.

6.1.2 Đóng góp của đồ án

- Xây dựng hoàn chỉnh pipeline cho bài toán anomaly detection từ xử lý dữ liệu, huấn luyện đến đánh giá
- So sánh nhiều cấu hình khác nhau:

- Mô hình (baseline vs advanced)
- Optimizer (Adam vs SGD)
- Regularization (Weight Decay vs Data Augmentation)
- Áp dụng trên nhiều dataset khác nhau (MVTec và CIFAR) để đánh giá tổng quát
- Xây dựng **giao diện GUI** giúp trực quan hóa kết quả (ảnh tái tạo, heatmap, score)
- Phân tích chi tiết kết quả thông qua các biểu đồ và metric như AUROC, PR-AUC

6.2 Hướng phát triển

- Thử các mô hình mạnh hơn như VAE hoặc GAN.
- Kết hợp thêm perceptual loss hoặc SSIM loss.
- Sử dụng learning rate scheduler để tối ưu train.
- Giữ nguyên kích thước CIFAR hoặc dùng model phù hợp ảnh nhỏ.
- Bổ sung thêm metric như Precision, Recall, F1-score.
- Đo thời gian train và inference.
- Tuning thêm batch size, learning rate và epoch.

Tài liệu tham khảo

- [1] Goodfellow, I., Bengio, Y., Courville, A. (2016). Deep Learning. MIT Press.
- [2] LeCun, Y., et al. (1998). Gradient-Based Learning Applied to Document Recognition.
- [3] Krizhevsky, A., et al. (2012). ImageNet Classification with Deep CNNs.
- [4] Hinton, G., Salakhutdinov, R. (2006). Reducing the Dimensionality of Data.
- [5] Vincent, P., et al. (2008). Stacked Denoising Autoencoders.
- [6] Hochreiter, S., Schmidhuber, J. (1997). Long Short-Term Memory.
- [7] Vaswani, A., et al. (2017). Attention Is All You Need.